

Previsão de Política Monetária: Estimação clássica e aprendizagem de máquina

Lucas Henrique de Oliveira - 12564332*

20 de dezembro de 2025

Resumo

A previsão e acompanhamento da inflação sempre foram objeto de intenso estudo e interesse de economistas no que tange à compreensão da política monetária. O presente artigo busca investigar e comparar, em termos de performance na previsão da inflação, ferramentas clássicas de previsão – em especial modelos VAR e ARIMA – e novas ferramentas de *machine learning* (ML) desenvolvidas intensamente nas últimas décadas. Os resultados do artigo apontam à dominância de modelos de ML sobre os modelos tradicionais, com desempenho de destaque aos modelos de árvore.

Palavras-chave Econometria de séries temporais, Aprendizagem de máquina, Política monetária

Códigos JEL: C14, C22, C52, C53

*Universidade de São Paulo

1 Introdução

Uma das principais atribuições da autoridade monetária é controlar o nível de preços. No caso do Brasil, o Banco Central do Brasil (Bacen) tem como sua principal ferramenta a política monetária e fixa a taxa Selic de modo a manter a inflação (mensurada principalmente pelo Índice de Preços ao Consumidor Amplo – IPCA) dentro da meta. Para tal, o Bacen acompanha o comportamento e modela a inflação fazendo uso de diversos artifícios.

De acordo com Ang, Bekaert e Wei (2007), as autoridades monetárias fazem uso de quatro métodos principais na previsão da inflação: modelos de séries de tempo, modelos estruturais, modelos de *asset pricing* e *surveys*. O BACEN se enquadra nessa generalização. São utilizados modelos estruturais como o Stochastic Analytical Model with a Bayesian Approach (SAMBA) e *surveys* como o Focus para a construção de previsões da inflação. Neste âmbito, o avanço intenso da literatura de aprendizagem de máquina nas últimas décadas tornou relevante a adoção dos mesmos por economistas (ATHEY; IMBENS, 2019), tanto na microeconomia quanto na macroeconomia. Isso traz à tona a importância da incorporação destes modelos aos arcabouços tradicionais de previsão da inflação, pois os mesmos são propícios para *big data* (VARIAN, 2014) ao possibilitarem a incorporação eficiente de um alto volume de variáveis e a modelagem de componentes não-lineares que não são facilmente incorporáveis a modelos estatísticos de séries de tempo tradicionais.

Notavelmente, há uma literatura incipiente que busca incorporar métodos de processamento natural de linguagem à identificação de choques de política monetária (ARUOBA; DRECHSEL, 2024). Entretanto o presente trabalho focará em métodos supervisionados e não-supervisionados de modo a enfatizar o poder destas ferramentas de incorporar informação não facilmente capturável por modelos lineares usuais. Breves explicações dos métodos utilizados no presente trabalho, e da base de dados construída, serão feitas na seção subsequente².

Assim, autores como Garcia, Medeiros e Vasconcelos (2017) e Medeiros et al. (2021) olham para os casos brasileiro e estadunidense, respectivamente, fazendo uso de modelos

de alta dimensionalidade (como Lasso e Ridge) — propícios sob condições de esparsidade adequadas —, e árvores de regressão. No caso brasileiro, em especial, o legado hiperinflacionário da década de 90 e a adoção recente do regime de metas em 1999 torna a previsão da inflação de curto-prazo especialmente relevante para a tomada de decisão de agentes econômicos. Logo, o presente trabalho visa estender análises existentes ao comparar modelos tradicionais VAR e ARIMA com modelos de regularização e árvores de regressão em termos de capacidade de previsão do IPCA, frisando a capacidade destes últimos modelos de modelar não-linearidades.

2 Metodologia

A escolha das variáveis relevantes à comparação é feita baseada em Kohlscheen (2021) e em Araujo e Gaglianone (2023), de onde também escolhemos os modelos de ML que serão utilizados para comparação com o VAR e ARIMA.

2.1 Dados

A variável dependente avaliada é a variação mês a mês (M.o.M). Para incorporar a implementação do regime de metas e a estabilização da inflação no início dos anos 2000, a data inicial da base se dá em janeiro de 2004 e se estende até setembro de 2025. As covariadas selecionadas foram extraídas do BCB, IBGE, FGV, IpeaData, Funcex e AN-BIMA. As transformações realizadas nos dados seguem McCracken e Ng (2016), tal que consideramos as seguinte transformações possíveis:

- | | | |
|-------------------|---------------------|--------------------------|
| 1. x_t , | 3. $\Delta^2 x_t$; | 5. $\Delta \ln(x_t)$; |
| 2. Δx_t ; | 4. $\ln(x_t)$; | 6. $\Delta^2 \ln(x_t)$. |

Para a estimação do VAR, utilizou-se o IPCA de preços de mercado, preços administrados, taxa real de juros de 1 ano (aqui usamos o swap 360d como proxy), a log-diferença da taxa de câmbio nominal (BRL/USD) e o hiato do produto (usando como proxy a série do IBC-BR ajustada pelo filtro HP). A escolha destas variáveis visa incorporar as




Figura 1: Evolução histórica do IPCA Geral (2004-2024)
Fonte: Elaboração própria.

dinâmicas temporais dos dois principais componentes da inflação no Brasil (preços de mercado e preços administrados) e o *pass-through* da inflação importada sobre preços domésticos.

Quanto aos modelos de ML, a seleção das covariadas se dá diretamente pelo processo de regularização e *bagging* dentro do conjunto de variáveis totais.

2.2 Modelos ARIMA e VAR

A modelagem univariada ARIMA envolve incorporar combinações lineares de componentes autorregressivos e os erros de previsão via médias móveis destes. A implementação é baseada no algoritmo de Hyndman e Khandakar (2008), fazendo uso combinado da minimização de critérios de informação e de testes de raiz unitária para a especificação do modelo, flexibilizando a metodologia Box-Jenkins clássica.

A modelagem multivariada é feita via VAR, onde incorporamos relações de contemporaneidade via empilhamento de processos $AR(p)$, o que nos permite modelar diretamente parte da endogeneidade das variáveis do sistema. A seleção da ordem de defasagens é feita via critérios de Schwarz-Bayes e Hannan-Quinn, que tendem a apresentar menor viés para modelos VAR. Como o interesse é preditivo, estimamos apenas o VAR em forma reduzida.

2.3 Modelos de *Shrinkage* e *Bagging*

No caso dos modelos de ML, fazemos o uso de duas classes de modelos: os modelos de *shrinkage* (regularização) LASSO, Ridge e Elastic Net e os modelos de *bagging* (florestas de regressão), onde se implementa *xgboost*, *Random Forest* e *lightgbm*. Por fim, incorporamos estes modelos em um *ensemble*, alocando pesos simples às combinações e construindo intervalos de previsão via *conformal prediction*, conforme sugerido por Wang et al. (2023).

2.4 Comparação e Implementação

Devido à dependência temporal presente nas séries, no lugar da validação cruzada ao treinamento dos modelos, separamos a amostra em três subperíodos. O primeiro e segundo subperíodo, T_1 e T_2 são utilizados para treino, e o último subperíodo, T_3 , para teste. No primeiro subperíodo, as realizações $t_1 = 1, 2, \dots, T_1 - 1, T_1$ são utilizadas para treino e contrapostas ao período subsequente T_2 e, no caso do *ensemble*, computa-se o peso das combinações. As realizações finais, $t_3 = T_2 + 1, \dots, T_3$, são utilizadas para avaliação dos modelos. Aqui consideramos $T_1 = 72$ meses, $T_2 = 120$ meses e $T_3 = 60$ meses. Ou seja, o primeiro período se estende de 2004 até 2010, o segundo de 2010 até 2019 e o terceiro período de 2020 até 2025.

Comparamos a performance de cada modelo utilizando como principal métrica a *mean-square error* (MSE), definida como $\sum_{i=1}^n (y_i - \tilde{y}_i)^2$, mas reportamos as outras métricas usuais. Verifica-se se as previsões são estatisticamente comparáveis via teste de Diebold-Mariano. Por fim, para os modelos de ML, implementamos os intervalos de previsão conformais, eliminando a necessidade de hipóteses restritivas sobre a distribuição dos erros. As transformações realizadas podem ser encontradas na tabela 5. As variáveis que não constam na tabela – os índice de inflação IPCA, IPC e IGP – foram utilizadas em sua variação percentual.

3 Resultados

Primeiramente avaliamos a performance do modelo ARIMA(1,0,1), cuja especificação foi encontrada via algoritmo de Hyndman e Khandakar (2008).

Tabela 1: Métricas de desempenho do modelo ARIMA(1,0,1)

Horizonte	RMSE	MSE	MAE	MAPE
1	0.73	0.54	0.73	3.50
3	0.58	0.33	0.56	4.17
6	0.43	0.18	0.37	2.39
9	0.36	0.13	0.30	1.76
12	0.44	0.19	0.37	1.45
15	0.43	0.18	0.37	1.29
18	0.40	0.16	0.34	1.13

Como se pode ver pela tabela, o modelo ARIMA tem dificuldade em realizar boas previsões do IPCA mês-a-mês em todos os horizontes, fato este possivelmente acentuado pelos choques nas cadeias de suprimento devido à pandemia de COVID-19 no início da década de 20. A melhor performance do modelo se dá para $h = 9$, com menores estatísticas de erro MAE, MSE e RMSE.

Em relação ao modelo VAR(1), a especificação escolhida pelo critério BIC foi $p = 1$. Conforme se pode ver pela tabela abaixo, a performance do VAR também não é promissora, tendo desempenho, em geral, pior que o modelo ARIMA(1,0,1) especificado, com o horizonte com melhor desempenho ocorrendo em $h = 18$.

Tabela 2: Métricas de desempenho do modelo VAR(1) por horizonte de previsão

Horizonte	RMSE	MSE	MAE	MAPE
$h = 1$	0.75	0.56	0.75	3.55
$h = 3$	0.65	0.42	0.65	4.96
$h = 6$	0.51	0.26	0.47	2.96
$h = 9$	0.43	0.19	0.38	2.19
$h = 12$	0.46	0.21	0.41	1.76
$h = 15$	0.44	0.19	0.39	1.54
$h = 18$	0.41	0.17	0.36	1.34

Novamente, parece razoável supor que houve impacto da pandemia do COVID-19 na performance dos modelos.

Os modelos tradicionais apresentaram desempenho sub-ótimo na previsão da inflação mês-a-mês. Entretanto, nota-se, em especial no caso do VAR, uma lenta diminuição do erro conforme se aumenta os horizontes. Um possível aprofundamento desta análise seria avaliar o desempenho destes modelos concentrando-se em horizontes de previsão mais distantes.

Por fim, o teste de Diebold-Mariano retornou $p\text{-valor} = 0.53$ e estatística de teste 0.62, o que leva à não-rejeição da hipótese nula de que não há diferença significativa entre os modelos estimados.

Tabela 3: Métricas de desempenho dos modelos de ML para o IPCA mês-a-mês.

Horizonte	Métrica	ElasticNet	Ridge	Lasso	RF	XGB	LGBM	Comb.
1	RMSE	0.350	0.050	0.340	0.000	0.000	0.010	0.100
	MSE	0.120	0.000	0.120	0.000	0.000	0.000	0.010
	MAE	0.350	0.050	0.340	0.000	0.000	0.010	0.100
	MAPE	1.650	0.240	1.630	0.000	0.010	0.070	0.490
3	RMSE	0.370	0.070	0.390	0.010	0.010	0.040	0.120
	MSE	0.140	0.010	0.150	0.000	0.000	0.000	0.020
	MAE	0.350	0.060	0.370	0.000	0.000	0.030	0.110
	MAPE	3.240	0.640	3.430	0.060	0.040	0.340	1.080
6	RMSE	0.350	0.060	0.360	0.010	0.010	0.060	0.110
	MSE	0.120	0.000	0.130	0.000	0.000	0.000	0.010
	MAE	0.300	0.060	0.310	0.000	0.010	0.040	0.090
	MAPE	2.030	0.400	2.110	0.040	0.030	0.250	0.650
9	RMSE	0.320	0.080	0.320	0.010	0.010	0.060	0.100
	MSE	0.100	0.010	0.100	0.000	0.000	0.000	0.010
	MAE	0.270	0.060	0.270	0.000	0.000	0.040	0.080
	MAPE	1.520	0.360	1.570	0.030	0.020	0.200	0.490
12	RMSE	0.450	0.080	0.450	0.060	0.060	0.090	0.150
	MSE	0.200	0.010	0.200	0.000	0.000	0.010	0.020
	MAE	0.370	0.070	0.370	0.030	0.030	0.070	0.120
	MAPE	1.310	0.280	1.340	0.040	0.030	0.180	0.420
15	RMSE	0.440	0.100	0.440	0.050	0.060	0.090	0.150
	MSE	0.190	0.010	0.190	0.000	0.000	0.010	0.020
	MAE	0.380	0.080	0.380	0.020	0.030	0.070	0.120
	MAPE	1.180	0.270	1.210	0.040	0.030	0.170	0.380
18	RMSE	0.430	0.090	0.430	0.050	0.050	0.100	0.140
	MSE	0.180	0.010	0.180	0.000	0.000	0.010	0.020
	MAE	0.370	0.080	0.370	0.020	0.020	0.070	0.110
	MAPE	1.080	0.250	1.100	0.030	0.030	0.160	0.340

RF: RandomForestRegressor; XGB: XGBRegressor; LGBM: LGBMRegressor.

Em relação aos modelos ML estimados, estes dominam estritamente os modelos clássicos em praticamente todos os horizontes. Isto ocorre tanto no caso dos modelos de regularização quanto no caso dos modelos de árvore. Aqui há uma pequena convergência no MSE com os modelos estatísticos tradicionais nos horizontes mais distantes ($h = 12$ em diante) com os modelos estatísticos clássicos.

Dentro dos modelos de regularização, o modelo Ridge teve desempenho superior aos modelos Lasso e ElasticNet, convergindo em performance com os modelos de árvores em praticamente todo horizonte de predição.

Quanto aos modelos de floresta, o XGBoost e o RandomForest dominaram tanto o LGBM quanto o *ensemble*, mesmo que estes também tenham tido bom desempenho preditivo. Aqui o modelo de *ensemble* foi estimado adotando pesos conforme Wang et al. (2023).

A dominância dos modelos de ML (em especial os modelos de *bagging*) aponta para a presença de forte não-linearidade na dinâmica da inflação, o que é dificilmente incorporado pelos modelos lineares, tradicionais ou não. Entretanto, a elevada performance *out-of-sample* abre espaço para uma preocupação com um potencial *overfitting* advindo de uma "sobretunagem" do modelo.

Tabela 4: Resultados do Teste Diebold-Mariano (Comparação Pair-wise)

Modelo A	Modelo B	Estat. DM	P-Valor	Vencedor ($p < 0.05$)
ElasticNet	Combination	4.168	< 0.001	Combination
Lasso	Combination	4.144	< 0.001	Combination
ElasticNet	XGBRFRegressor	4.091	< 0.001	XGBRFRegressor
ElasticNet	RandomForest	4.077	< 0.001	RandomForest
Lasso	XGBRFRegressor	4.068	< 0.001	XGBRFRegressor
Lasso	RandomForest	4.055	< 0.001	RandomForest
ElasticNet	LGBMRegressor	4.018	< 0.001	LGBMRegressor
Lasso	LGBMRegressor	3.994	< 0.001	LGBMRegressor
ElasticNet	Ridge	3.881	0.0001	Ridge
Ridge	Lasso	-3.864	0.0001	Ridge
XGBRFRegressor	Combination	-3.288	0.0010	XGBRFRegressor
RandomForest	Combination	-3.198	0.0014	RandomForest
RandomForest	LGBMRegressor	-3.042	0.0024	RandomForest
XGBRFRegressor	LGBMRegressor	-3.001	0.0027	XGBRFRegressor
Ridge	RandomForest	2.361	0.0182	RandomForest
Ridge	XGBRFRegressor	2.098	0.0359	XGBRFRegressor
LGBMRegressor	Combination	-2.020	0.0433	LGBMRegressor
Ridge	Combination	-1.718	0.0857	<i>Empate Estatístico</i>
RandomForest	XGBRFRegressor	-1.298	0.1941	<i>Empate Estatístico</i>
Ridge	LGBMRegressor	-0.286	0.7746	<i>Empate Estatístico</i>
ElasticNet	Lasso	0.019	0.9847	<i>Empate Estatístico</i>

Nota: Valores de P-Valor arredondados. "Combination" refere-se ao modelo de ensemble.

Os testes pareados de Diebold-Mariano, tomando um nível de significância de 5%, apontam para uma superioridade preditiva dos modelos XGBoost e RandomForest. Dado

que há evidência pelo teste de que estes são estatisticamente equivalentes, de um ponto de vista computacional, isto sugere a utilização do XGBoost, devido ao menor custo de implementá-lo.

Analogamente, em termos pareados, o modelo Ridge domina os modelos de regularização.

A performance inferior do modelo *ensemble*, ao qual há sugestão de equivalência estatística ao modelo Ridge, sugere uma reestimação dos pesos para diminuir a relevância dos modelos de regularização ou até mesmo a eliminação deste modelos do ensemble.

Os gráficos das previsões aos horizontes 3 e 6 podem ser visualizados na seção de figuras.

4 Conclusão

O presente trabalho visou avaliar a performance de modelos de Machine Learning na previsão da inflação em comparação com modelos estatísticos tradicionais.

Neste âmbito, tanto os modelos de regularização quanto os de *bagging* apresentaram performance superior aos modelos estatísticos tradicionais, com os modelos Random-Forest, LGBM e XGBoost dominando dentre todos os modelos. Entretanto, há uma preocupação em relação a estes modelos estarem potencialmente sofrendo de *overfitting*, dada a performance quase-perfeita das previsões. Uma análise de robustez considerando horizontes diferentes aos períodos t_1 , t_2 e t_3 seria adequado à validação dos resultados.

Tendo isto em mente, a performance superior dos modelos de árvores reforça a presença de elementos não-lineares presente na dinâmica inflacionária, e a necessidade de investigar o *black-box* dos modelos de ML de modo a incorporar estas não-linearidades no arcabouço preditivo de economistas, reforçando a hipótese enunciada no início do artigo. Ademais, os resultados decepcionantes dos modelos Lasso e Ridge apontam para a investigação de métodos de regularização alternativos, como o Adalasso ou Iterative Lasso.

Neste âmbito, também seria adequado reespecificar o modelo ensemble, seja via atu-

alização de pesos, ou reespecificação dos modelos de regularização a fim de otimizar o desempenho do mesmo. Por fim, os resultados do artigo vão em encontro da literatura de previsão atual, corroborando o poder preditivo dos modelos de ML moderno e os posicionando como poderosos instrumentos ao acompanhamento e implementação de política monetária.

Referências

ANG, A.; BEKAERT, G.; WEI, M. Do macro variables, asset markets, or surveys forecast inflation better? *Journal of Monetary Economics*, v. 54, n. 4, p. 1163–1212, 2007. ISSN 0304-3932. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0304393206002303>.

ARAUJO, G. S.; GAGLIANONE, W. P. Machine learning methods for inflation forecasting in brazil: New contenders versus classical models. *Latin American Journal of Central Banking*, v. 4, n. 2, p. 100087, 2023. ISSN 2666-1438. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2666143823000042>.

ARUOBA, S. B.; DRECHSEL, T. Identifying monetary policy shocks: A natural language approach. *American Economic Journal: Macroeconomics*, p. Forthcoming, 2024. Disponível em: topcat.aeaweb.org.

ATHEY, S.; IMBENS, G. *Machine Learning Methods Economists Should Know About*. 2019. Disponível em: <https://arxiv.org/abs/1903.10075>.

GARCIA, M. G.; MEDEIROS, M. C.; VASCONCELOS, G. F. Real-time inflation forecasting with high-dimensional models: The case of brazil. *International Journal of Forecasting*, v. 33, n. 3, p. 679–693, 2017. ISSN 0169-2070. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0169207017300262>.

HYNDMAN, R. J.; KHANDAKAR, Y. Automatic time series forecasting: The forecast package for r. *Journal of Statistical Software*, v. 27, n. 3, p. 1–22, 2008. Disponível em: <https://www.jstatsoft.org/index.php/jss/article/view/v027i03>.

KOHLSCHEEN, E. *What does machine learning say about the drivers of inflation?* [S.l.], 2021. Disponível em: <https://ideas.repec.org/p/bis/biswps/980.html>.

MCCRACKEN, M. W.; NG, S. Fred-md: A monthly database for macroeconomic research. *Journal of Business & Economic Statistics*, ASA Website, v. 34, n. 4, p. 574–589, 2016. Disponível em: <https://doi.org/10.1080/07350015.2015.1086655>.

MEDEIROS, M. C. et al. Forecasting inflation in a data-rich environment: The benefits of machine learning methods. *Journal of Business & Economic Statistics*, ASA Website, v. 39, n. 1, p. 98–119, 2021. Disponível em: <https://doi.org/10.1080/07350015.2019.1637745>.

VARIAN, H. R. Big data: New tricks for econometrics. *Journal of Economic Perspectives*, v. 28, n. 2, p. 3–28, May 2014. Disponível em: <https://www.aeaweb.org/articles?id=10.1257/jep.28.2.3>.

WANG, X. et al. Forecast combinations: An over 50-year review. *International Journal of Forecasting*, v. 39, n. 4, p. 1518–1547, 2023. ISSN 0169-2070. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0169207022001480>.

Tabelas

Tabela 5: Transformações aplicadas

Variável	Código	Descrição
1. ind_extract	5	$\Delta \ln(x_t)$
2. ind_manuf	5	$\Delta \ln(x_t)$
3. ind_capital	5	$\Delta \ln(x_t)$
4. ind_intermediate	5	$\Delta \ln(x_t)$
5. ind_consumer	5	$\Delta \ln(x_t)$
6. ind_durables	5	$\Delta \ln(x_t)$
7. ind_semidurables	5	$\Delta \ln(x_t)$
8. ind_nondurables	5	$\Delta \ln(x_t)$
9. sales_fuel	5	$\Delta \ln(x_t)$
10. sales_hypermart	5	$\Delta \ln(x_t)$
11. sales_furniture	5	$\Delta \ln(x_t)$
12. sales_textiles	5	$\Delta \ln(x_t)$
13. sales_vehicles_pmc	5	$\Delta \ln(x_t)$
14. sales_total	5	$\Delta \ln(x_t)$
15. impo_agriculture	5	$\Delta \ln(x_t)$
16. impo_manufacturing	5	$\Delta \ln(x_t)$
17. impo_mining	5	$\Delta \ln(x_t)$
18. impo_others	5	$\Delta \ln(x_t)$
19. impo_total	5	$\Delta \ln(x_t)$
20. expo_agriculture	5	$\Delta \ln(x_t)$
21. expo_manufacturing	5	$\Delta \ln(x_t)$
22. expo_mining	5	$\Delta \ln(x_t)$
23. expo_others	5	$\Delta \ln(x_t)$
24. expo_total	5	$\Delta \ln(x_t)$
25. us_epu	2	Δx_t
26. eur_epu	2	Δx_t
27. ger_epu	2	Δx_t
28. uk_epu	2	Δx_t
29. can_epu	2	Δx_t
30. chi_epu	2	Δx_t
31. ind_epu	2	Δx_t
32. rus_epu	2	Δx_t
Continua na página seguinte		

Tabela 5 – Continuação

Variável	Código	Descrição
33. ita_epu	2	Δx_t
34. spa_epu	2	Δx_t
35. bra_epu	2	Δx_t
36. aus_epu	2	Δx_t
37. jap_epu	2	Δx_t
38. sin_epu	2	Δx_t
39. ibov	5	$\Delta \ln(x_t)$
40. tjlp	2	Δx_t
41. real_rate	2	Δx_t
42. prod_veiculos_total	5	$\Delta \ln(x_t)$
43. prod_caminhoes	5	$\Delta \ln(x_t)$
44. prod_onibus	5	$\Delta \ln(x_t)$
45. vendas_veiculos_total	5	$\Delta \ln(x_t)$
46. vendas_veiculos_nacionais	5	$\Delta \ln(x_t)$
47. energia_comercial	5	$\Delta \ln(x_t)$
48. energia_residencial	5	$\Delta \ln(x_t)$
49. energia_industrial	5	$\Delta \ln(x_t)$
50. energia_total	5	$\Delta \ln(x_t)$
51. salario_minimo	5	$\Delta \ln(x_t)$
52. base_monetaria	5	$\Delta \ln(x_t)$
53. externo_reservas_int	2	Δx_t
54. cambio_usd_ptax	5	$\Delta \ln(x_t)$
55. fiscal_dlsp_brl	2	Δx_t
56. pib_12m_c	6	$\Delta^2 \ln(x_t)$
57. fiscal_dlsp_pib	6	$\Delta^2 x_t$
58. fiscal_resultado_primario_fluxo	5	$\Delta \ln(x_t)$
59. fiscal_resultado_primario_pib_12m	6	$\Delta^2 x_t$
60. steel_prod	5	$\Delta \ln(x_t)$
61. reer_ipca	5	$\Delta \ln(x_t)$
62. credito_saldo_total	6	$\Delta^2 \ln(x_t)$
63. credito_saldo_pj	6	$\Delta^2 \ln(x_t)$
64. credito_saldo_pf	6	$\Delta^2 \ln(x_t)$
65. credito_saldo_livres	6	$\Delta^2 \ln(x_t)$
66. credito_concessoes_livres	6	$\Delta^2 \ln(x_t)$
67. credito_spread_livre	6	$\Delta^2 \ln(x_t)$
Continua na página seguinte		

Tabela 5 – Continuação

Variável	Código	Descrição
68. credito_inadimplencia	6	$\Delta^2 \ln(x_t)$
69. externo_transacoes_correntes_usd	6	$\Delta^2 \ln(x_t)$
70. externo_idp_12m_usd	6	$\Delta^2 \ln(x_t)$
71. externo_invest_carteira_fluxo	6	$\Delta^2 \ln(x_t)$
72. uci_industry	2	Δx_t
73. ibc_br	5	$\Delta \ln(x_t)$
74. ibc_br_sa	5	$\Delta \ln(x_t)$
75. taxa_desemprego	6	$\Delta^2 x_t$
76. externo_transacoes_correntes_pib_12m	6	$\Delta^2 \ln(x_t)$
77. ic_br_total	6	$\Delta^2 \ln(x_t)$
78. ic_br_agro	5	$\Delta \ln(x_t)$
79. ic_br_metal	5	$\Delta \ln(x_t)$
80. ic_br_energia	5	$\Delta \ln(x_t)$
81. monetario_m1	5	$\Delta \ln(x_t)$
82. monetario_m2	6	$\Delta^2 \ln(x_t)$
83. monetario_m3	6	$\Delta^2 \ln(x_t)$
84. monetario_m4	6	$\Delta^2 \ln(x_t)$
85. caged_saldo_antigo	2	Δx_t
86. massa_rendimento_real	6	$\Delta^2 \ln(x_t)$
87. uci_fgv	2	Δx_t
88. meta_selic	2	Δx_t

Figuras




Figura 1: ARIMA(1,0,1), $h = 3$




Figura 2: VAR(1), $h = 3$




Figura 3: Modelos Regularizados, $h = 3$




Figura 4: Modelos de Árvore, $h = 3$




Figura 5: Modelos Regularizados, $h = 6$




Figura 6: Modelos de Árvore, $h = 6$